Министерство образования Республики Беларусь

Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет компьютерных систем и сетей

Кафедра программного обеспечения информационных технологий

Методы машинного обучения

ОТЧЕТ

по лабораторной работе №2

Вариант 3

Выполнил
Студент гр. 351002 Михальков А. Д.

Проверил Лебедевич А. В.

Минск 2026

СОДЕРЖАНИЕ

1 Цель выполнения 3
2 Теоретическая основа 3
2.1 Разведочный анализ данных (EDA) и структура датасета 3
2.2 Анализ пропущенных значений и методы их обработки 4
2.3 Статистические аномалии (выбросы) и метод межквартильного размаха (IQR) 4
2.4 Графические средства визуализации распределений 5
2.5 Конструирование новых признаков (Feature Engineering) 5
2.6 Преобразование категориальных данных 5
2.7 Масштабирование числовых признаков 6
3 Индивидуальное задание 7
4 Код решения 8
5 Скриншоты выполнения 12
6 Выводы 16

1 Цель выполнения

Овладение практическими навыками сбора, первичной обработки и разведочного анализа данных (Exploratory Data Analysis, EDA) для решения прикладных задач машинного обучения. Изучение статистических и визуальных методов выявления пропусков и аномальных значений (выбросов) в выборке, а также освоение алгоритмов их устранения на основе межквартильного размаха (IQR). Приобретение практических навыков конструирования новых информативных признаков (Feature Engineering), методов числового кодирования категориальных переменных (One-Hot Encoding, бинаризация) и масштабирования данных с использованием процедур стандартизации (StandardScaler) и нормализации (MinMaxScaler).

2 Теоретическая основа

2.1 Разведочный анализ данных (EDA) и структура датасета

Разведочный анализ данных (Exploratory Data Analysis, EDA) представляет собой начальный этап работы с данными в машинном обучении, целью которого является исследование основных статистических характеристик выборки, выявление скрытых закономерностей, обнаружение аномалий и проверка гипотез без построения сложных прогностических моделей.

В прикладном анализе исходные данные организуются в виде датасета (набора данных), представляющего собой двумерную матрицу (таблицу):

– каждая строка таблицы соответствует отдельному объекту исследования (наблюдению, экземпляру);

– каждый столбец соответствует конкретной характеристике объекта, называемой признаком (feature).

Признаки классифицируются на числовые (непрерывные и дискретные) и категориальные (номинальные и порядковые). Среди признаков также выделяют независимые переменные (факторы) и зависимую (целевую) переменную, значение которой подлежит прогнозированию алгоритмом. В среде разработки Python основным инструментом манипулирования табличными данными является библиотека Pandas, предоставляющая структуру DataFrame, а базовый аудит структуры выборки выполняется методами .shape (определение размерности), .head() (визуальный контроль первых записей) и .info() (анализ типов данных и расхода оперативной памяти).

2.2 Анализ пропущенных значений и методы их обработки

Пропущенные значения (Missing Values, в среде Python обозначаемые как NaN – Not a Number) возникают в данных вследствие технических сбоев оборудования, человеческого фактора при заполнении форм или ошибок передачи информации по каналам связи. Наличие неполных записей препятствует корректному функционированию большинства математических алгоритмов оптимизации и регрессии, требующих непрерывных числовых матриц.

В разведочном анализе данных применяется двухэтапный подход к контролю пропусков:

1 Статистический аудит, заключающийся в подсчете числа неопределенных значений по каждому столбцу с помощью функций .isnull().sum() или .isna().sum().

2 Графическая верификация посредством построения тепловых карт (Heatmap), где бинарная матрица пропусков визуализируется цветовым градиентом, позволяя мгновенно выявить структурные разрывы в данных.

При обнаружении пропусков в машинном обучении применяются две основные стратегии:

a) элиминация (удаление) строк или столбцов с пропусками, допустимая лишь в случаях, когда объем утерянной информации не превышает 3–5 % от общего объема выборки;

b) импутация (восстановление данных), при которой пропуски в числовых переменных замещаются мерами центральной тенденции: средним арифметическим значением (при симметричном нормальном распределении) либо медианой (при наличии асимметрии и тяжелых хвостов распределения). Для категориальных признаков применяется подстановка моды (наиболее часто встречающегося значения) либо выделение пропусков в отдельную категорию.

2.3 Статистические аномалии (выбросы) и метод межквартильного размаха (IQR)

Выбросы – это редкие экстремальные значения, резко отличающиеся от общей массы выборки (например, штучные спорткары среди обычных седанов). Они смещают средние значения и искажают работу моделей регрессии.

Для их поиска применяется метод межквартильного размаха (IQR). Данные делятся на четыре равные части: вычисляются 25-й перцентиль (граница нижних 25 % выборки) и 75-й перцентиль (граница верхних 75 %). Разница между ними образует ядро нормальных данных — диапазон IQR. Допустимыми границами признаются значения, отстоящие от ядра не более

чем на полтора таких размаха. Наблюдения, выходящие за эти рамки, удаляются из таблицы либо ограничиваются пороговыми значениями.

2.4 Графические средства визуализации распределений

Для визуального анализа данных в рамках EDA используются следующие средства:

Гистограмма и кривая плотности (KDE): отображают частоту появления значений и форму распределения, показывая скошенность данных и наличие тяжелых «хвостов».

Диаграмма размаха (BoxPlot): графически отображает ядро данных в виде прямоугольника («ящика») и границы нормы («усы»). Все точки за пределами усов являются выбросами.

Диаграммы категорий (Bar Plot, Pie Chart): показывают долю каждого класса и помогают выявить дисбаланс категорий (например, преобладание бензина над дизелем).

Матрица корреляций (Heatmap): цветовая таблица взаимосвязи числовых признаков. Позволяет определить характеристики, сильнее всего влияющие на целевой показатель, и исключить дублирующие параметры.

2.5 Конструирование новых признаков (Feature Engineering)

Feature Engineering – это процесс создания новых числовых или логических колонок на основе исходных данных с целью повышения точности моделей машинного обучения. Алгоритмы регрессии не способны самостоятельно улавливать сложные нелинейные соотношения (например, делить мощность мотора на массу автомобиля).

Создание производных признаков (удельная динамика, средний расход топлива, текстовый парсинг марки) обогащает выборку предметными знаниями, снижает уровень шума и упрощает процесс обучения классификаторов и регрессоров.

2.6 Преобразование категориальных данных

Математические алгоритмы работают исключительно с числовыми матрицами и не поддерживают строковые текстовые категории. Простое присвоение словам порядковых номеров (1, 2, 3) недопустимо, так как это создает ложное ощущение математического превосходства одних категорий над другими.

Для корректной оцифровки текста применяются:

– Бинаризация: перевод признаков с двумя исходами в числовой флаг 0 или 1 (например, тип расположения мотора).

– One-Hot Encoding (прямое кодирование): создание отдельного бинарного столбца под каждую категорию (кузов, привод, топливо). Для исключения избыточности (ловушки фиктивных переменных) один базовый столбец отбрасывается.

2.7 Масштабирование числовых признаков

Признаки в датасетах часто измерены в несопоставимых шкалах: цена измеряется десятками тысяч, а число дверей – единицами. В алгоритмах, основанных на вычислении геометрических расстояний и градиентном спуске, крупные числа полностью подавляют малые параметры.

Для выравнивания весов применяются два метода:

– Стандартизация (StandardScaler): трансформирует признак так, чтобы его среднее значение равнялось 0, а стандартный разброс – 1. Метод устойчив к наличию редких крупных чисел и является стандартом для линейных моделей.

– Нормализация (MinMaxScaler): жестко сжимает значения в интервал от 0 до 1, где минимум становится нулем, а максимум – единицей. Применяется в нейросетях и алгоритмах, чувствительных к границам числовых шкал.

3 Индивидуальное задание

В рамках лабораторной работы необходимо выполнить следующие этапы:

1 Импортировать набор данных с использованием библиотеки Pandas, определить его размерность, перечень признаков и структуру типов данных.

2 Выполнить комплексный анализ качества выборки:

– проверить данные на наличие пропусков статистическими методами и средствами графической визуализации (построение тепловой карты пропусков), при наличии пропусков выполнить их заполнение;

– исследовать распределение числовых параметров и выявить аномальные значения (выбросы) с использованием статистических метрик, гистограмм частот и диаграмм размаха (BoxPlot);

– реализовать устранение выбросов на основе метода межквартильного размаха (IQR);

– графически подтвердить факт отсутствия аномалий и стабилизации распределений после очистки данных.

3 Провести этап конструирования признаков (Feature Engineering) и преобразования качественных данных:

– сгенерировать новые информативные признаки на основе предметной области (не менее двух);

– выполнить первичное исследование категориальных признаков (кузов, тип топлива, привод) с использованием столбчатых и секторных диаграмм;

– построить матрицу корреляций числовых характеристик с целевым признаком цены;

– применить числовое кодирование категориальных параметров: выполнить бинаризацию признаков с двумя исходами и прямое кодирование (One-Hot Encoding) для многоклассовых категорий.

4 Выполнить масштабирование числовых признаков:

– реализовать процедуру стандартизации данных (StandardScaler) с приведением к нулевому среднему и единичной дисперсии;

– реализовать процедуру нормализации данных (MinMaxScaler) с масштабированием в диапазон от 0 до 1;

– построить сравнительные гистограммы распределений до и после масштабирования и сформировать сводную таблицу статистических параметров;

– экспортировать очищенные и масштабированные наборы данных в файлы формата .csv.

4 Код решения

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style="whitegrid")
plt.rcParams['figure.figsize'] = (10, 6)

df = pd.read_csv('CarPrice_Assignment.csv')

print(f"Размер датасета: {df.shape[0]} строк и {df.shape[1]} признаков.")
df.head()

df.info()

missing_values = df.isnull().sum()
print("Количество пропусков в каждом столбце:")
print(missing_values[missing_values > 0])

if missing_values.sum() == 0:
    print("\nЯвных пропусков (NaN) в исходном датасете нет!")
else:
    print(f"\nВсего пропусков: {missing_values.sum()}")

plt.figure(figsize=(12, 4))
sns.heatmap(df.isnull(), cbar=False, yticklabels=False, cmap='viridis')
plt.title("Тепловая карта пропусков (пустые желтые полосы означали бы NaN)",
fontsize=14)
plt.show()

print("Статистическое описание признаков:")
display(df[['price', 'enginesize', 'horsepower']].describe())

fig, axes = plt.subplots(2, 3, figsize=(18, 10))

features = ['price', 'enginesize', 'horsepower']
titles = ['Цена (Price)', 'Объем двигателя (Engine Size)', 'Мощность (Horsepower)']

for i, col in enumerate(features):
    sns.histplot(df[col], kde=True, ax=axes[0, i], color='royalblue')
    axes[0, i].set_title(f'Распределение: {titles[i]}', fontsize=12)

    sns.boxplot(x=df[col], ax=axes[1, i], color='salmon')
    axes[1, i].set_title(f'BoxPlot (выбросы): {titles[i]}', fontsize=12)

plt.tight_layout()
plt.show()

def remove_outliers_iqr(data, columns):
    df_clean = data.copy()
    for col in columns:
        Q1 = df_clean[col].quantile(0.25)
        Q3 = df_clean[col].quantile(0.75)
        IQR = Q3 - Q1
        lower_bound = Q1 - 1.5 * IQR
```

```
        upper_bound = Q3 + 1.5 * IQR

        df_clean = df_clean[(df_clean[col] >= lower_bound) & (df_clean[col] <=
upper_bound)]
    return df_clean

df_cleaned = remove_outliers_iqr(df, ['price', 'enginesize', 'horsepower'])

print(f"Строк до удаления выбросов: {df.shape[0]}")
print(f"Строк после удаления выбросов: {df_cleaned.shape[0]}")
print(f"Удалено аномальных записей: {df.shape[0] - df_cleaned.shape[0]}")

fig, axes = plt.subplots(1, 3, figsize=(18, 5))
for i, col in enumerate(features):
    sns.boxplot(x=df_cleaned[col], ax=axes[i], color='lightgreen')
    axes[i].set_title(f'BoxPlot ПОСЛЕ очистки: {titles[i]}', fontsize=12)

plt.tight_layout()
plt.show()

print("=== АНАЛИЗ КАТЕГОРИАЛЬНЫХ ПРИЗНАКОВ ===")

fig, axes = plt.subplots(1, 3, figsize=(18, 5))

df['carbody'].value_counts().plot(kind='bar', ax=axes[0], color='cornflowerblue',
edgecolor='black')
axes[0].set_title('Количество авто по типам кузова (carbody)')
axes[0].tick_params(axis='x', rotation=45)

df['fueltype'].value_counts().plot(kind='pie', ax=axes[1], autopct='%1.1f%%',
colors=['#ff9999','#66b3ff'])
axes[1].set_title('Соотношение бензин / дизель (fueltype)')
axes[1].set_ylabel('')

sns.boxplot(x='drivewheel', y='price', data=df, ax=axes[2], palette='Set2')
axes[2].set_title('Зависимость цены от типа привода (drivewheel)')

plt.tight_layout()
plt.show()

print("=== ТЕПЛОВАЯ КАРТА КОРРЕЛЯЦИЙ ЧИСЛОВЫХ ПРИЗНАКОВ ===")

plt.figure(figsize=(12, 8))
corr_matrix = df[['carlength', 'carwidth', 'curbweight', 'enginesize', 'horsepower',
'citympg', 'price']].corr()
sns.heatmap(corr_matrix, annot=True, fmt='.2f', cmap='coolwarm', linewidths=0.5)
plt.title('Матрица корреляций ключевых характеристик с ценой', fontsize=14)
plt.show()

print("=== ГЕНЕРАЦИЯ НОВЫХ ПРИЗНАКОВ ===")

df_processed = df_cleaned.copy() if 'df_cleaned' in locals() else df.copy()

df_processed['Brand'] = df_processed['CarName'].apply(lambda x: x.split()[0].lower())
df_processed['Brand'] = df_processed['Brand'].replace({
    'maxda': 'mazda',
    'porcshce': 'porsche',
    'toyouta': 'toyota',
```

```
    'vokswagen': 'volkswagen',
    'vw': 'volkswagen'
})

df_processed['Power_to_Weight'] = df_processed['horsepower'] /
df_processed['curbweight']

df_processed['Avg_MPG'] = (df_processed['citympg'] + df_processed['highwaympg']) / 2

price_median = df_processed['price'].median()
df_processed['Is_Luxury'] = (df_processed['price'] > price_median).astype(int)

door_map = {'two': 2, 'four': 4}
df_processed['Door_Count_Num'] = df_processed['doornumber'].map(door_map)

print(f"Успешно создано 5 новых признаков:")
new_features = ['Brand', 'Power_to_Weight', 'Avg_MPG', 'Is_Luxury', 'Door_Count_Num']
display(df_processed[new_features].head())

fig, axes = plt.subplots(1, 3, figsize=(16, 4))
df_processed['Power_to_Weight'].hist(bins=20, ax=axes[0], color='skyblue',
edgecolor='black')
axes[0].set_title('Распределение Power_to_Weight')

df_processed['Avg_MPG'].hist(bins=20, ax=axes[1], color='lightgreen',
edgecolor='black')
axes[1].set_title('Распределение Avg_MPG')

sns.countplot(x='Is_Luxury', data=df_processed, ax=axes[2], palette='pastel')
axes[2].set_title('Количество авто по сегментам (Is_Luxury)')

plt.tight_layout()
plt.show()

print("=== КОДИРОВАНИЕ КАТЕГОРИАЛЬНЫХ ПРИЗНАКОВ ===")

df_processed['Engine_Location_Rear'] = (df_processed['enginelocation'] ==
'rear').astype(int)

ohe_cols = ['fueltype', 'aspiration', 'carbody', 'drivewheel']
print(f"Применяем One-Hot Encoding для признаков: {ohe_cols}")

df_encoded = pd.get_dummies(df_processed, columns=ohe_cols, drop_first=True)

cols_to_drop = ['car_ID', 'CarName', 'Brand', 'doornumber', 'enginelocation',
'enginetype', 'cylindernumber', 'fuelsystem']
df_final = df_encoded.drop(columns=cols_to_drop)

print("\nКодирование успешно завершено!")
print(f"Размерность таблицы после кодирования: {df_final.shape[0]} строк и
{df_final.shape[1]} признаков.")
print("\nПервые 5 строк подготовленного датасета:")
display(df_final.head())

from sklearn.preprocessing import StandardScaler, MinMaxScaler

print("=== МАСШТАБИРОВАНИЕ ЧИСЛОВЫХ ПРИЗНАКОВ ===")
```

```
continuous_cols = [
    'wheelbase', 'carlength', 'carwidth', 'carheight', 'curbweight',
    'enginesize', 'boreratio', 'stroke', 'compressionratio',
    'horsepower', 'peakrpm', 'citympg', 'highwaympg',
    'Power_to_Weight', 'Avg_MPG', 'price'
]

scaler_std = StandardScaler()
df_standardized = df_final.copy()
df_standardized[continuous_cols] =
scaler_std.fit_transform(df_standardized[continuous_cols])

scaler_minmax = MinMaxScaler()
df_normalized = df_final.copy()
df_normalized[continuous_cols] =
scaler_minmax.fit_transform(df_normalized[continuous_cols])

stats_comparison = pd.DataFrame({
    'Исходные': [df_final['price'].mean(), df_final['price'].std(),
df_final['price'].min(), df_final['price'].max()],
    'StandardScaler': [df_standardized['price'].mean(),
df_standardized['price'].std(), df_standardized['price'].min(),
df_standardized['price'].max()],
    'MinMaxScaler': [df_normalized['price'].mean(), df_normalized['price'].std(),
df_normalized['price'].min(), df_normalized['price'].max()]
}, index=['Среднее (Mean)', 'Станд. откл. (Std)', 'Минимум (Min)', 'Максимум (Max)'])

print("Сравнение статистик признака 'price':")
display(stats_comparison.round(4))

fig, axes = plt.subplots(1, 3, figsize=(18, 5))

sns.histplot(df_final['price'], kde=True, ax=axes[0], color='steelblue')
axes[0].set_title('1. Исходные данные (Price)')

sns.histplot(df_standardized['price'], kde=True, ax=axes[1], color='darkorange')
axes[1].set_title('2. После StandardScaler (mean=0, std=1)')

sns.histplot(df_normalized['price'], kde=True, ax=axes[2], color='seagreen')
axes[2].set_title('3. После MinMaxScaler (от 0 до 1)')

plt.tight_layout()
plt.show()

df_standardized.to_csv('car_price_standardized.csv', index=False)
df_normalized.to_csv('car_price_normalized.csv', index=False)

print("Обработанные датасеты успешно сохранены:")
print("1. car_price_standardized.csv (стандартизированные данные)")
print("2. car_price_normalized.csv (нормализованные данные)")
```

5 Скриншоты выполнения

Размер датасета: 205 строк и 26 признаков.

	car_ID	symboling	CarName	fueltype	aspiration	doornumber	carbody	drivewheel	enginelocation	wheelbase	...	enginesize	fuelsystem	boreratio
0	1	3	alfa-romero giulia	gas	std	two	convertible	rwd	front	88.6	...	130	mpfi	3.47
1	2	3	alfa-romero stelvio	gas	std	two	convertible	rwd	front	88.6	...	130	mpfi	3.47
2	3	1	alfa-romero Quadrifoglio	gas	std	two	hatchback	rwd	front	94.5	...	152	mpfi	2.68
3	4	2	audi 100 ls	gas	std	four	sedan	fwd	front	99.8	...	109	mpfi	3.19
4	5	2	audi 100ls	gas	std	four	sedan	4wd	front	99.4	...	136	mpfi	3.19

5 rows × 26 columns

Рисунок 1 – Результаты загрузки датасета

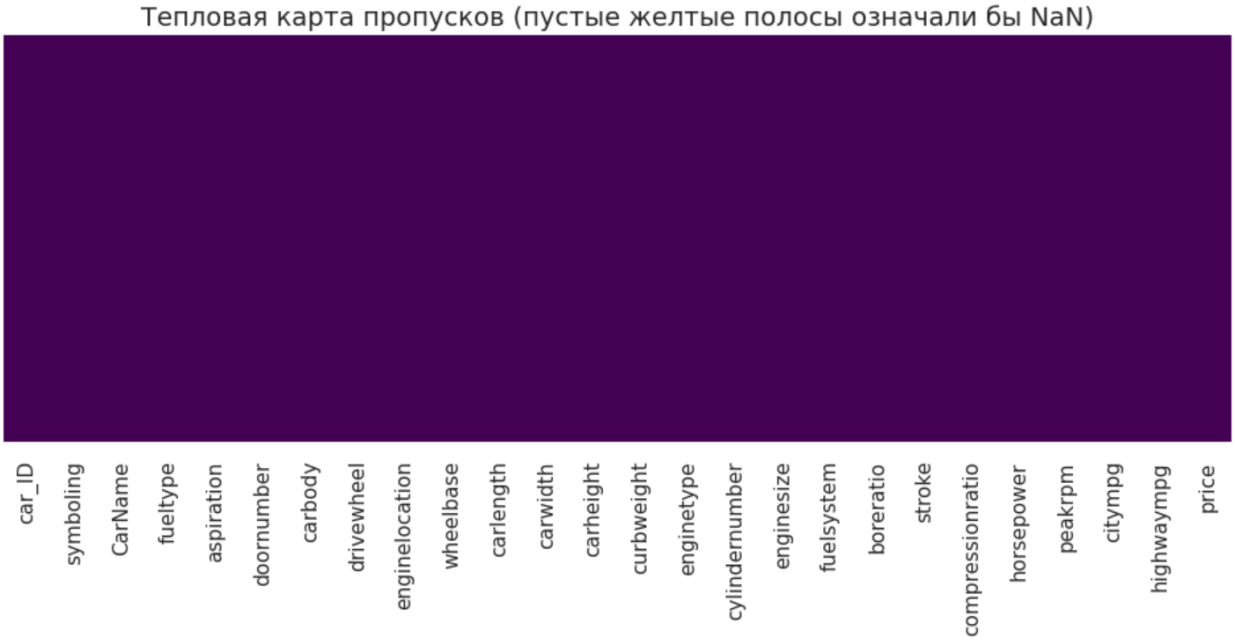


Рисунок 2 – Тепловая карта пропусков

	price	enginesize	horsepower
count	205.000000	205.000000	205.000000
mean	13276.710571	126.907317	104.117073
std	7988.852332	41.642693	39.544167
min	5118.000000	61.000000	48.000000
25%	7788.000000	97.000000	70.000000
50%	10295.000000	120.000000	95.000000
75%	16503.000000	141.000000	116.000000
max	45400.000000	326.000000	288.000000

Рисунок 3 – Статистическое описание признаков

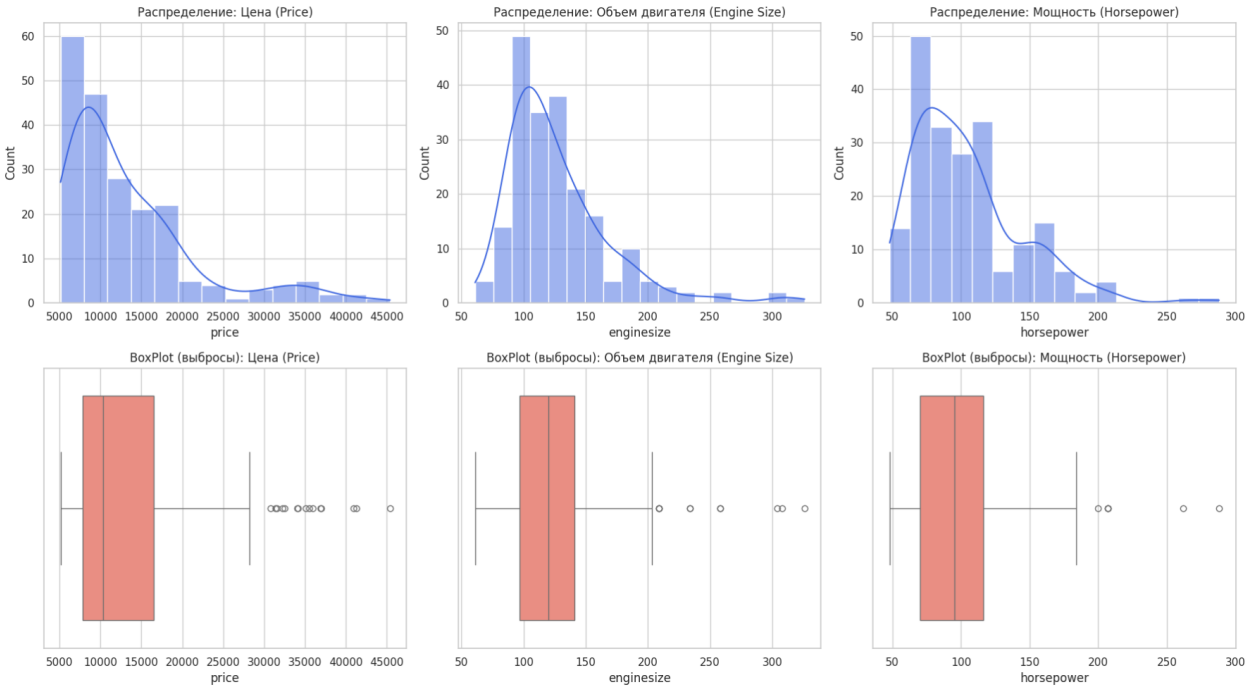


Рисунок 4 – Графики статистического описания признаков

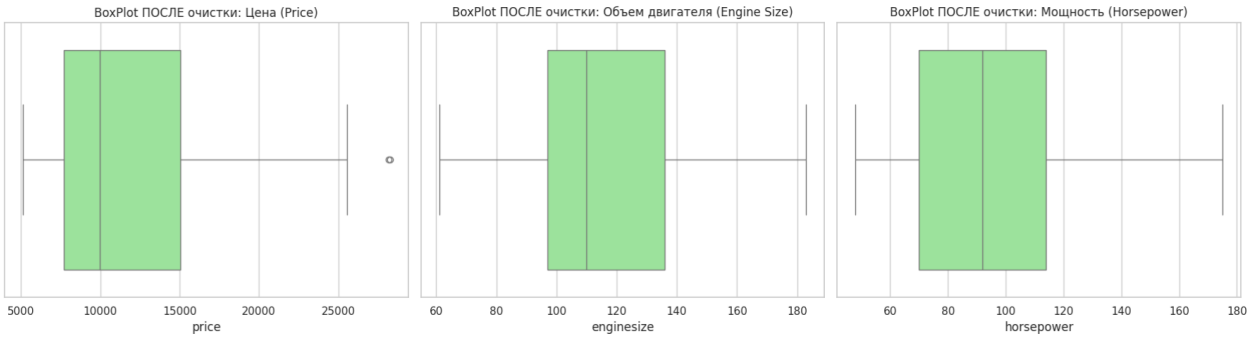


Рисунок 5 – Результаты устранения выбросов

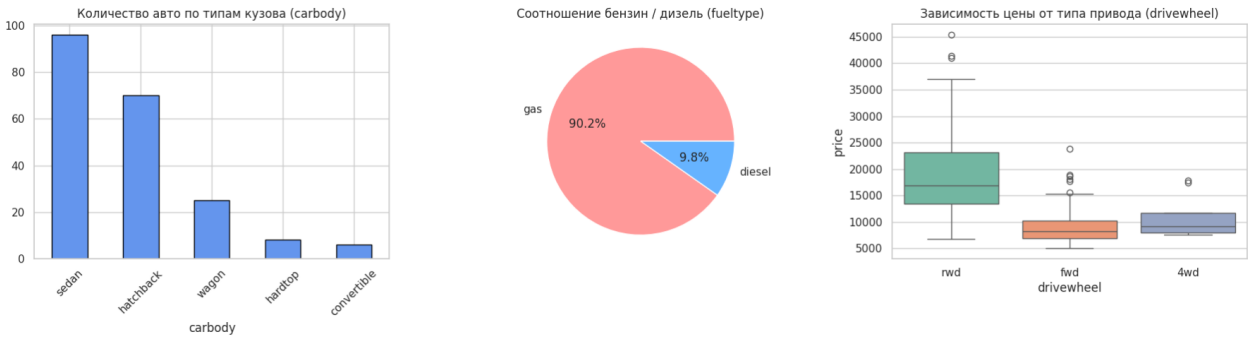


Рисунок 6 – Анализ категориальных признаков



Рисунок 7 – Матрица корреляций ключевых характеристик

	Brand	Power_to_Weight	Avg_MPG	Is_Luxury	Door_Count_Num
0	alfa-romero	0.043564	24.0	1	2
1	alfa-romero	0.043564	24.0	1	2
2	alfa-romero	0.054552	22.5	1	2
3	audi	0.043646	27.0	1	4
4	audi	0.040722	20.0	1	4

Рисунок 8 – Результат генерации новых признаков

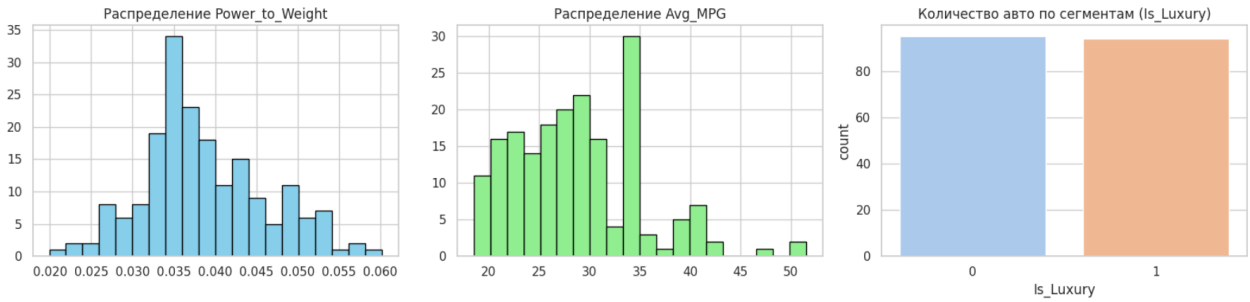


Рисунок 9 – Графики распределения новых признаков

	symboling	wheelbase	carlength	carwidth	carheight	curbweight	enginesize	boreratio	stroke	compressionratio	...	Door_Count_Num	Engine_Location_F
0	3	88.6	168.8	64.1	48.8	2548	130	3.47	2.68	9.0	...	2	
1	3	88.6	168.8	64.1	48.8	2548	130	3.47	2.68	9.0	...	2	
2	1	94.5	171.2	65.5	52.4	2823	152	2.68	3.47	9.0	...	2	
3	2	99.8	176.6	66.2	54.3	2337	109	3.19	3.40	10.0	...	4	
4	2	99.4	176.6	66.4	54.3	2824	136	3.19	3.40	8.0	...	4	

Рисунок 10 – Результат кодирования признаков

	Исходные	StandardScaler	MinMaxScaler
Среднее (Mean)	11466.0697	0.0000	0.2745
Станд. откл. (Std)	4945.5136	1.0027	0.2138
Минимум (Min)	5118.0000	-1.2870	0.0000
Максимум (Max)	28248.0000	3.4024	1.0000

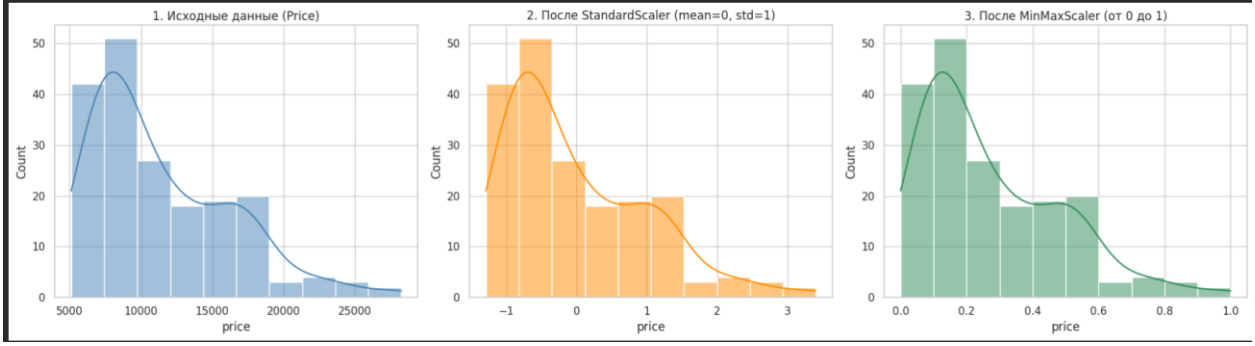


Рисунок 11 – Результат масштабирования признаков

6 Выводы

В ходе выполнения лабораторной работы были освоены практические навыки разведочного анализа данных (EDA), очистки выборки от аномалий, конструирования новых информативных признаков и масштабирования числовых шкал для задач машинного обучения на примере датасета характеристик автомобилей

На основании проведенных исследований и полученных графических результатов сделаны следующие выводы:

1 Статистический анализ и визуализация с помощью тепловой карты подтвердили полное отсутствие пропущенных значений (NaN) во всех 26 столбцах исходной таблицы (205 записей), что исключило необходимость применения процедур импутации (восстановления) данных на начальном этапе.

2 С использованием диаграмм размаха (BoxPlot) и статистических перцентилей были выявлены выраженные выбросы в характеристиках стоимости (price), мощности (horsepower) и объема двигателя (enginesize), искажавшие нормальный вид распределений в сторону завышения средних оценок. Применение фильтрации по методу межквартильного размаха позволило устранить 16 аномальных записей (эксклюзивные спорткары и автомобили люкс-сегмента), стабилизировав выборку до 189 однородных наблюдений. Повторные контрольные графики BoxPlot подтвердили устранение аномальных хвостов.

3 Анализ категориальных признаков показал сильную зависимость стоимости от типа привода: автомобили с задним приводом (rwd) в среднем в два раза дороже переднеприводных моделей (fwd). Построение матрицы корреляций выявило наивысшую прямую связь цены с объемом двигателя, снаряженной массой и мощностью, а также обратную зависимость с расходом топлива.

4 Сформировано 5 новых предметных характеристик: марка автомобиля с очисткой от опечаток (Brand), удельная тяговооруженность (Power_to_Weight), сбалансированный расход топлива (Avg_MPG), бинарный ценовой класс (Is_Luxury) и числовой эквивалент количества дверей (Door_Count_Num). Это позволило передать будущим моделям нелинейные физические соотношения в готовом виде.

5 Реализована бинаризация признака расположения силового агрегата (Engine_Location_Rear) и прямое унитарное кодирование (One-Hot Encoding) для признаков кузова, топлива и привода. Применение параметра drop_first=True исключило эффект мультиколлинеарности (ловушку фиктивных переменных), расширив размерность подготовленного пространства признаков до 28 числовых колонок.

6 Реализованы алгоритмы стандартизации (StandardScaler) и нормализации (MinMaxScaler). Статистическое сравнение доказало, что

StandardScaler успешно привел данные к нулевому математическому ожиданию и единичному разбросу, а MinMaxScaler строго ограничил значения интервалом [0; 1]. Сравнительные гистограммы подтвердили, что масштабирование изменило исключительно шаг координатной сетки, полностью сохранив исходную форму и топологию распределений величин.

Таким образом, цель лабораторной работы достигнута, все поставленные задачи выполнены в полном объеме.